Research Assistant: практическая ценность

Чекпойнт 02 / 10 ноября 2026

Кому нужен поиск по документам

Исследователь или специалист по качеству задает вопрос к набору документов и получает фрагменты с номерами страниц. Так проще найти определение, проверить требование и вернутся к полному контексту. Поиск не заменяет чтение стандарта и не подтверждает соответствие организации его требованиям.

Что проверено на этом этапе

Прототип обрабатывает три цифровых PDF по менеджменту качества: 105 страниц, из которых 90 включены в поиск. Отдельные модули извлекают текст, режут его на чанки, строят индекс BM25 и считают метрики. Панель Streamlit показывает облака слов, источники, найденные фрагменты и влияние параметров. Длйа нового пользовательского корпуса потребуются новый реестр источников и разметка.

Как оценивать пользу

Заказчик может собрать реальные вопросы специалистов и отметить фрагменты с ответами. Основные показатели: доля вопросов с доказательством в TOP-1, TOP-5 и TOP-10, время поиска, достаточность контекста и корректность ссылки на страницу. Синтезированные вопросы этого чекпойнта подходят для отладки, но не заменяют независимой проверки человеком.

Ограничения и риски

Текстовый слой PDF может разрывать слова или терять структуру таблиц. Поиск по словам пропускает часть синонимов; длинные чанки увеличивают нагрузку при чтении. Нужно проверять редакции стандартов и права на передачу копий. Конфиденциальные документы нельзя отправлять внешнему генератору без согласия владельца. Сканы, таблицы как изображения и автоматическая проверка актуальности пока не поддержаны.

Следующая итерация

Сначала нужны независимые вопросы и полная проверка доказательств. Затем к тому же корпусу и тесту можно добавить векторный поиск и повторное ранжирование. Сбор библиографии, граф публикаций и ответ по нескольким источникам остаются следующими частями архитектуры. Результаты на трэ ГОСТах не переносятся автоматически на научные статьи.